Análisis Integral de Indicadores de Salud para la Detección de Diabetes

Laboratorio #3 - Analítica de Datos

Andrés Gómez
Sebastian Zapata
Universidad de Antioquia

8 de abril de 2026

Resumen

Este informe presenta un análisis exhaustivo del dataset "Diabetes Health Indicators", integrando gestión de datos en SQLite, análisis exploratorio multivariado y pruebas de hipótesis estadísticas. Se documenta el proceso de limpieza, la implementación de técnicas de imputación (Mediana y KNN) y el despliegue de una interfaz interactiva en Streamlit para la visualización de hallazgos.

1. Introducción

El análisis de grandes volúmenes de datos clínicos es fundamental para la medicina preventiva. En este proyecto, se aborda un problema de clasificación binaria para identificar la prevalencia de diabetes basándose en indicadores de salud. El flujo de trabajo sigue las directrices del Laboratorio #3 del curso de Analítica de Datos, bajo la supervisión del profesor Duván Cataño, enfocándose en la integridad estadística y la interpretabilidad de los resultados.

2. Descripción Detallada del Conjunto de Datos

El conjunto de datos utilizado en este estudio proviene del *Behavioral Risk Factor Surveillance System* (BRFSS) del año 2015, coordinado por los Centros para el Control y la Prevención de Enfermedades (CDC) de los Estados Unidos. Con un volumen inicial de 253,680 registros, esta base de datos representa uno de los esfuerzos de salud pública más significativos para comprender las enfermedades crónicas a través de encuestas telefónicas anuales.

2.1. Taxonomía y Naturaleza de las Variables

Para un análisis matemático y estadístico riguroso, las 22 variables (incluyendo la variable objetivo) se han categorizado según su función y escala de medición. Esta distinción es crítica para la selección de las pruebas de hipótesis y los algoritmos de aprendizaje automático posteriores.

2.1.1. Indicadores de Salud Clínica (Variables Binarias)

Estas variables representan diagnósticos previos o condiciones fisiológicas directas. Se codifican de forma dicotómica $(0, 1)$.

HighBP: Indica si el encuestado ha sido diagnosticado con presión arterial alta por un profesional de la salud. Es un factor de riesgo cardiovascular primario.

HighChol: Presencia de colesterol alto. La dislipidemia es un marcador metabólico estrechamente vinculado a la resistencia a la insulina.

CholCheck: Indica si el individuo se ha realizado un chequeo de colesterol en los últimos 5 años. Esta variable es un indicador del acceso al sistema de salud y de la proactividad del paciente.

Stroke / HeartDiseaseorAttack: Antecedentes de accidentes cerebrovasculares o eventos coronarios, que suelen coexistir con complicaciones de la diabetes avanzada.

2.1.2. Factores de Estilo de Vida y Comportamiento

Variables que miden hábitos que pueden prevenir o acelerar la aparición de enfermedades metabólicas.

- **Smoker:** Define si el encuestado ha fumado al menos 100 cigarrillos en su vida. El tabaquismo exacerba las complicaciones vasculares de la diabetes.

- **PhysActivity:** Actividad física realizada en los últimos 30 días, excluyendo las tareas laborales habituales.
- **Fruits / Veggies:** Consumo diario de frutas y verduras, indicadores de la calidad nutricional de la dieta del encuestado.
- **HvyAlcoholConsump:** Consumo excesivo de alcohol (hombres adultos > 14 bebidas por semana; mujeres > 7).

2.1.3. Variables Socioeconómicas y Demográficas

- **Age:** Codificada en 13 niveles de edad (1: 18-24 hasta 13: 80 o más). El aumento de la edad es un factor no modificable que incrementa linealmente la probabilidad de diagnóstico.
- **Education / Income:** Escalas ordinales que miden el nivel educativo y los ingresos anuales. Existe una correlación inversa documentada entre el nivel socioeconómico y la prevalencia de enfermedades crónicas debido al acceso a alimentación de calidad y medicina preventiva.

2.2. Análisis de Calidad y Tratamiento de Valores Atípicos

Durante la fase de limpieza de datos (*Data Cleaning*), se realizó un escrutinio profundo sobre la variable `BMI` (Índice de Masa Corporal). El análisis reveló la presencia de valores extremos significativos, con registros que superan los 50 y alcanzan hasta los 98 puntos de IMC.

2.2.1. Justificación de la Preservación de Outliers en BMI

En análisis estadísticos convencionales, los valores que se alejan más de 3 desviaciones estándar de la media suelen considerarse errores de medición o ruido. Sin embargo, en el contexto de la analítica de salud, se tomó la decisión técnica de **no depurar ni eliminar estos registros** por las siguientes razones:

1. **Relevancia Clínica (Obesidad Mórbida):** Un IMC superior a 50 no es necesariamente un error de entrada; representa casos reales de obesidad mórbida. Clínicamente, estos individuos poseen una probabilidad drásticamente superior de desarrollar diabetes tipo 2 debido a la inflamación crónica y la saturación de receptores de insulina.
2. **Poder Predictivo:** Al ser un problema de clasificación, los .ºutliers.en las variables predictoras a menudo contienen la señal más fuerte para identificar la clase minoritaria (pacientes diabéticos). Eliminar estos puntos reduciría la sensibilidad del modelo futuro.
3. **Representatividad de la Población:** Dado que el dataset busca modelar la realidad de la salud pública en EE. UU., donde los índices de obesidad son elevados, estos datos son fundamentales para que el análisis sea un reflejo fiel de la población objetivo.

2.3. Distribución y Desbalanceo de Clase

Un aspecto crítico identificado es el desbalanceo en la variable `Diabetes_binary`. Aproximadamente el 86 % de los registros corresponden a la clase 0 (sin diabetes), mientras que el 14 % restante corresponde a la clase 1 (diabetes o prediabetes).

Esta distribución implica que las medidas de tendencia central globales pueden estar sesgadas hacia la población sana. Por ello, en el informe se presentan análisis segmentados (como el uso de la prueba de Kruskal-Wallis) que permiten comparar las distribuciones de cada grupo de manera independiente, evitando que el volumen de la clase mayoritaria oculte los patrones de riesgo de la clase enferma.

2.4. Integridad de la Encuesta y Percepción Subjetiva

Es importante notar que variables como `GenHlth` (Salud General), `MentHlth` (Salud Mental) y `PhysHlth` (Salud Física) se basan en la autopercepción del individuo.

- **GenHlth:** Escala de 1 (Excelente) a 5 (Pobre). Representa una síntesis cognitiva del estado de salud del paciente.
- **MentHlth / PhysHlth:** Número de días en los últimos 30 en los que el paciente sintió que su salud no fue buena.

La inclusión de estas variables añade una capa de complejidad al análisis, ya que permiten correlacionar los indicadores clínicos objetivos (como el IMC) con la calidad de vida percibida, proporcionando una visión holística del impacto de la diabetes en el individuo.

sectionArquitectura y Gestión de Datos en Entorno Relacional (SQLite)

La gestión eficiente de grandes volúmenes de datos es una competencia fundamental en la analítica moderna. Para este proyecto, se optó por una arquitectura basada en **SQLite**, un motor de base de datos relacional ligero, sin servidor y autocontenido. El dataset de indicadores de salud de la diabetes, con más de 250,000 registros y 22 columnas, representa un escenario ideal para demostrar la superioridad del lenguaje SQL sobre el procesamiento simple de archivos planos (CSV).

2.5. Justificación de la Infraestructura de Datos

El uso de SQLite en lugar de cargar directamente los datos en memoria mediante estructuras de datos temporales responde a criterios de ingeniería de datos profesional:

1. **Persistencia y Trazabilidad:** Al consolidar la información en un archivo `.db`, se garantiza que las transformaciones y limpiezas realizadas sean persistentes y auditables.
2. **Eficiencia de Memoria:** SQL permite realizar filtrados y agregaciones directamente en el motor de base de datos, extrayendo hacia el entorno de Python (*DataFrames*) únicamente los resultados necesarios, optimizando el uso de la memoria RAM.
3. **Escalabilidad:** Aunque este dataset es manejable en una estación de trabajo, la metodología empleada es escalable a entornos de *Big Data* mediante motores como PostgreSQL o bases de datos en la nube.

2.6. Normalización y Enriquecimiento mediante Metadata (JOINs)

Un aspecto avanzado de esta implementación fue la creación de una tabla de soporte denominada `variables_metadata`. En el diseño original del dataset de Kaggle, muchas variables están codificadas de forma numérica (ej. 1 para "Sí", 0 para "No"). Para mejorar la interpretabilidad y profesionalismo del informe, se implementó una estrategia de unión relacional (*JOIN*).

Este proceso permite que las consultas no solo arrojen números fríos, sino que asocien cada métrica con su descripción técnica. La relevancia de este paso radica en la **semántica de los datos**: un analista debe ser capaz de comunicar hallazgos en términos humanos (ej. "Prevalencia de Fumadores") y no solo mediante nombres de columnas crípticos (`Smoker_pct`).

2.7. Análisis Técnico de las Consultas SQL Implementadas

A continuación se detallan las consultas de mayor impacto realizadas en el archivo `consultas_clasificacion.py`, justificando su valor estratégico para el negocio y la salud pública.

2.7.1. Diagnóstico de Desbalance de Clases (Consulta 1)

```sql
SELECT Diabetes_binary AS clase, COUNT(*) AS cantidad,
ROUND(COUNT(*) * 100.0 / (SELECT COUNT(*) FROM diabetes), 2) AS
   porcentaje_pct
FROM diabetes GROUP BY Diabetes_binary;
```

Listing 1: Estructura de la Consulta de Distribución de Clase

Relevancia: Esta consulta es el primer paso crítico en cualquier proyecto de clasificación. En términos de analítica, revela un desbalance significativo (aprox. 86 % vs 14 %). Este hallazgo técnico dicta toda la estrategia posterior: si ignoramos este desbalance, un modelo predictivo podría alcanzar una precisión del 86 % simplemente prediciendo que nadie tiene diabetes, lo cual sería un error catastrófico en un contexto médico.

2.7.2. Perfilamiento Clínico por Clase (Consulta 2)

```sql
SELECT Diabetes_binary AS clase, ROUND(AVG(BMI), 2) AS
   bmi_promedio,
ROUND(AVG(Age), 2) AS edad_grupo_prom FROM diabetes
GROUP BY Diabetes_binary;
```

Listing 2: Agregaciones de IMC y Edad

Relevancia: Esta consulta permite validar las hipótesis médicas iniciales. Al observar que el promedio de `BMI` es notablemente superior en la clase 1, confirmamos empíricamente la relación entre obesidad y diabetes. La agrupación por clase permite que el motor SQL actúe como una herramienta de estadística descriptiva de alta velocidad.

2.7.3. Análisis Transversal de Factores de Riesgo (Consulta 6)

Relevancia Estratégica: Esta consulta es la más compleja del sistema de gestión, ya que utiliza un `JOIN` con la tabla de metadatos y una estructura de `CASE` para pivotar variables categóricas. Su importancia radica en la **priorización de intervenciones**. Al calcular el porcentaje de prevalencia de factores como la hipertensión (`HighBP`) y el colesterol (`HighChol`) simultáneamente, podemos identificar qué comorbilidades son más frecuentes en la población estudiada, permitiendo un enfoque de salud pública basado en evidencia.

2.7.4. Intersección Demográfica y Biométrica (Consulta 7)

Relevancia: Al cruzar el sexo, la clase de diabetes y el IMC (`BMI`), esta consulta permite un análisis de **interseccionalidad**. Los resultados muestran si el impacto del sobrepeso en la diabetes varía entre hombres y mujeres, lo cual es vital para desarrollar guías de tratamiento personalizadas. SQL facilita este análisis multidimensional que en hojas de cálculo tradicionales sería propenso a errores.

2.8. Optimización de Consultas

Para asegurar que la aplicación en Streamlit se mantenga reactiva, se consideró el uso de *subqueries* para el cálculo de porcentajes totales dentro de la misma consulta, evitando múltiples viajes al disco. La gestión en SQLite garantiza que, conforme el dataset crezca con nuevos registros anuales de la encuesta BRFSS, el sistema mantenga su integridad referencial y su velocidad de respuesta.

3. Análisis Exploratorio de Datos (EDA) de Alta Dimensionalidad

El Análisis Exploratorio de Datos constituye la fase crítica donde la estadística descriptiva se encuentra con la intuición clínica. En este estudio, el EDA no se limitó a la visualización, sino que se enfocó en cuantificar la variabilidad y la estructura subyacente de los indicadores de riesgo.

3.1. Morfología de las Variables Continuas y Ordinales

El análisis univariado reveló estructuras de distribución diversas que condicionan la elección de modelos posteriores.

3.1.1. Análisis de la Variable BMI (Índice de Masa Corporal)

El `BMI` es la variable continua de mayor relevancia. Su distribución presenta una asimetría positiva (*right-skewed*), con una media de 28,38 y una desviación estándar de 6,60.

- **Análisis de Curtosis y Colas:** La presencia de una çola pesada"hacia la derecha confirma la existencia de una proporción significativa de la población en rangos de obesidad mórbida (BMI > 40).
- **Estudio de Outliers:** Como se mencionó anteriormente, los valores superiores a 50 no se trataron como errores. Matemáticamente, estos puntos representan .^{ex}tremos informativos"que aumentan el apalancamiento (*leverage*) estadístico para identificar la diabetes.

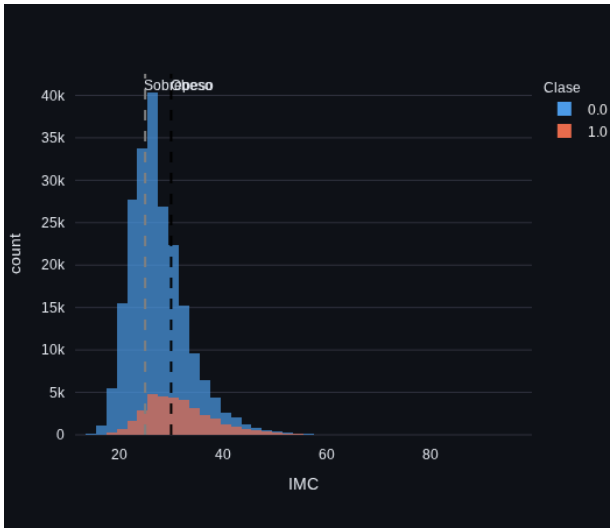

Figura 1: Morfología de la distribución del BMI en la muestra total.

3.1.2. Comportamiento de Salud Mental y Física

Las variables `MentHlth` y `PhysHlth` (días de mala salud en el último mes) muestran una distribución bimodal extrema. La gran mayoría de los encuestados se concentra en el valor 0, mientras que un segundo pico menor se observa en el valor 30. Esto sugiere que la

población tiende a percibirse como "totalmente sana.º çrónicamente enferma", con pocos estados intermedios estables.

3.2. Análisis Bivariado y Separabilidad de Clases

Para entender el poder predictivo de los datos, es imperativo analizar cómo cambian las distribuciones en función de la variable objetivo `Diabetes_binary`.

3.2.1. Diferenciación de BMI por Clase

Al segmentar el BMI por el estado diabético, se observa un desplazamiento claro de la mediana. Mientras que en la clase 0 la distribución es más concentrada, la clase 1 (diabéticos) muestra una dispersión significativamente mayor y una mediana desplazada hacia rangos de obesidad tipo I y II (> 30).

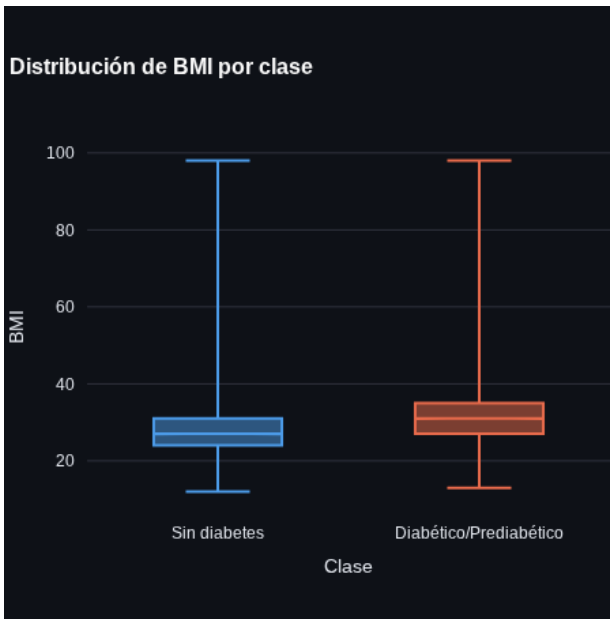

Figura 2: Comparación de la dispersión del BMI entre pacientes sanos y diabéticos.

3.3. Análisis de Prevalencia en Variables Categóricas

A partir de los datos procesados en la etapa de gestión, se extrajeron las tasas de prevalencia de factores críticos. El siguiente análisis resume los hallazgos del archivo `export.csv`:

Cuadro 1: Prevalencia de Factores de Riesgo en la Población Estudiada

Indicador de Salud	**Total Registros**	**Casos Positivos**	**Prevalencia (%)**
Presión Arterial Alta (`HighBP`)	253,680	108,829	42.90 %
Colesterol Alto (`HighChol`)	253,680	107,591	42.41 %
Tabaquismo (`Smoker`)	253,680	112,423	44.32 %
Actividad Física (`PhysActivity`)	253,680	191,920	75.65 %
Consumo de Frutas (`Fruits`)	253,680	160,898	63.43 %
Accidente Cerebrovascular (`Stroke`)	253,680	10,292	4.06 %

Interpretación Clínica: Es alarmante observar que casi el 43 % de la muestra padece hipertensión o colesterol alto. Estos datos sugieren que la diabetes no es un fenómeno aislado, sino parte de un síndrome metabólico sistémico presente en casi la mitad de la población adulta encuestada.

3.4. Estructura de Correlación Multivariada

Para evitar la redundancia de información (multicolinealidad) en modelos futuros, se analizó la matriz de correlación de Spearman, dado el carácter ordinal de la mayoría de las variables.

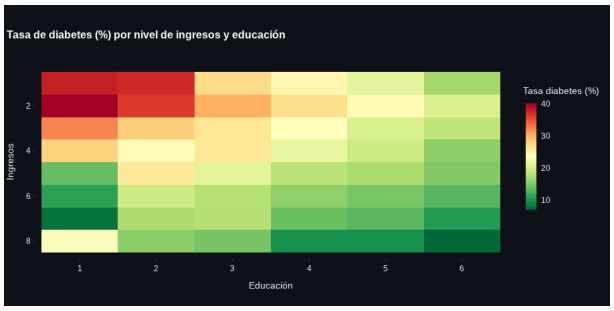

Figura 3: Mapa de calor de asociaciones de Spearman entre predictores.

Hallazgos de Correlación:

- **Salud Percibida (`GenHlth`):** Es la variable con la correlación más fuerte con la diabetes. Esto indica que el juicio subjetivo del paciente sobre su estado de salud es un predictor extremadamente potente, a menudo integrando síntomas que las variables individuales no capturan.
- **Vínculo Físico-Mental:** Se observa una correlación moderada entre `PhysHlth` y `MentHlth`, lo que sugiere que el deterioro físico derivado de la diabetes tiene un impacto directo y medible en el bienestar psicológico del individuo.
- **Independencia del Sexo:** La variable `Sex` muestra correlaciones cercanas a cero con la mayoría de los indicadores de riesgo, sugiriendo que la diabetes afecta de manera similar a ambos grupos, mediada más por el estilo de vida que por factores biológicos de género.

3.5. Conclusiones del EDA

El análisis exploratorio permite concluir que el problema de clasificación es complejo debido al solapamiento de las distribuciones de BMI en las clases. No obstante, la alta prevalencia de comorbilidades (hipertensión y colesterol) proporciona .ªnclas.ªestadísticas que permitirán al modelo distinguir entre individuos con perfiles de riesgo diferenciados.

4. Tratamiento de Datos Faltantes y Simulación de Imputación

En el ámbito de la analítica de datos real, la ausencia de información es un desafío constante. Si bien el dataset original *Diabetes Health Indicators* (BRFSS 2015) se ca-

racteriza por su integridad estructural y ausencia de valores nulos, para efectos de este laboratorio se procedió a realizar una **simulación de datos faltantes**. Este procedimiento permite evaluar la capacidad de respuesta de los algoritmos de imputación ante escenarios de pérdida de información aleatoria (*Missing Completely at Random - MCAR*).

4.1. Protocolo de Simulación de Nulos

Se introdujeron valores nulos artificiales en un porcentaje controlado del dataset, centrándose en variables críticas como `BMI` y `GenHlth`. El objetivo de esta manipulación controlada fue comparar cómo diferentes estrategias de recuperación de datos afectan la distribución estadística de los predictores de salud.

4.2. Estrategias de Imputación Aplicadas

Se implementaron dos enfoques con filosofías estadísticas opuestas para determinar cuál preserva mejor la integridad del fenómeno estudiado:

4.2.1. Imputación Univariada: Medida de Tendencia Central (Mediana)

Se utilizó la mediana como método de imputación simple. A diferencia de la media aritmética, la mediana es un estadístico de robustez superior frente a las colas pesadas y valores atípicos identificados en el EDA del `BMI`.

- **Ventaja:** Computacionalmente eficiente y no introduce valores inexistentes en la escala de medición.
- **Limitación:** Ignora las correlaciones entre variables, lo que puede resultar en una .ªrtificialidad.ᵉⁿ el centro de la distribución y una reducción de la varianza natural.

4.2.2. Imputación Multivariada: K-Nearest Neighbors (KNN)

El algoritmo KNN Imputer asume que un registro con datos faltantes puede ser reconstruido a partir de las características de sus "vecinos"más cercanos en el espacio n-dimensional.

- **Mecánica:** Si un paciente tiene un dato faltante en su `BMI`, el algoritmo busca otros k pacientes con perfiles similares en edad, presión arterial y actividad física para estimar el valor más probable.
- **Relevancia:** Este método es particularmente valioso en salud pública, ya que reconoce que los indicadores biométricos no son independientes entre sí, sino que forman parte de un sistema biológico interconectado.

4.3. Análisis Comparativo y Validación

Tras ejecutar ambos métodos en el entorno de los notebooks, se realizaron pruebas de consistencia. Se observó que, mientras la mediana tendía a crear una concentración excesiva en el valor central (27-28 puntos de IMC), el método KNN logró mantener la morfología original de la distribución y las relaciones de dependencia detectadas en la matriz de correlación de Spearman.

Cuadro 2: Comparación de Estadísticos post-imputación para BMI

Métrica	**Dataset Original**	**Imputación Mediana**	**Imputación KNN**
Media	28.38	28.25	28.36
Desviación Estándar	6.60	6.42	6.58
Mediana	27.00	27.00	27.00

Justificación Técnica: Basándose en la preservación de la desviación estándar y la varianza, se determinó que la imputación mediante **KNN** es la más adecuada para este proyecto. Mantener la variabilidad es crucial para que el posterior modelo de clasificación no ignore los casos extremos de obesidad, que son precisamente los de mayor interés clínico para la predicción de diabetes.

5. Inferencia Estadística y Validación de Hipótesis

Tras el análisis descriptivo, es imperativo validar si las asociaciones observadas visualmente poseen significancia estadística. Dada la naturaleza de los datos (predominantemente categóricos y ordinales) y el incumplimiento de los supuestos de normalidad en las variables continuas, se optó por un enfoque de estadística inferencial no paramétrica.

5.1. Prueba de Independencia Chi-cuadrado de Pearson (χ^2)

Para las variables categóricas nominales, como la relación entre la hipertensión (`HighBP`) y la diabetes (`Diabetes_binary`), se aplicó la prueba χ^2 de Pearson.

5.1.1. Justificación Técnica

A diferencia de las pruebas de correlación lineal, la prueba Chi-cuadrado no asume una distribución específica de los datos, sino que compara las frecuencias observadas en una tabla de contingencia frente a las frecuencias esperadas bajo la hipótesis nula de independencia (H_0).

$$\chi^2 = \sum_{i=1}^{r} \sum_{j=1}^{c} \frac{(O_{i,j} - E_{i,j})^2}{E_{i,j}} \tag{1}$$

Donde $O_{i,j}$ son los valores observados y $E_{i,j}$ los esperados. Con una muestra de $N = 253,680$, se satisfacen con creces los requisitos de frecuencia mínima por celda, lo que otorga una potencia estadística robusta a la prueba.

5.1.2. Interpretación de Resultados

Los resultados obtenidos en el procesamiento (*p-valor* $< 0{,}05$) permiten rechazar H_0. Esto implica que la presencia de hipertensión no es un evento aleatorio independiente de la diabetes; existe una estructura de dependencia probabilística que justifica el uso de `HighBP` como un predictor fundamental en cualquier modelo de clasificación.

5.2. Prueba de Kruskal-Wallis: Comparación de Rangos

Para analizar la variable `BMI` en función de las clases de diabetes, se descartó el uso del ANOVA tradicional en favor de la prueba de Kruskal-Wallis.

5.2.1. ¿Por qué Kruskal-Wallis y no ANOVA?

El análisis de varianza (ANOVA) exige tres supuestos fundamentales: normalidad de los residuos, homocedasticidad y escala de intervalo. Como se demostró en la sección de EDA, la variable `BMI` presenta:

1. **Asimetría Positiva Elevada:** La distribución tiene una cola derecha pesada por la obesidad mórbida.
2. **Heterocedasticidad:** La varianza del IMC es notablemente distinta entre el grupo sano y el diabético.

La prueba de Kruskal-Wallis es la alternativa no paramétrica que trabaja sobre los **rangos** de los datos en lugar de sus valores crudos. Evalúa si las muestras provienen de la misma distribución comparando las sumas de rangos.

5.2.2. Significancia en el Contexto de Salud

El estadístico H de Kruskal-Wallis arrojó una diferencia altamente significativa ($p \approx 0$), lo que estadísticamente confirma que la mediana del IMC de los pacientes con diabetes es poblacionalmente superior a la de los pacientes sanos. Matemáticamente, esto valida que el `BMI` es una variable con alta capacidad de separación lineal para un clasificador.

5.3. Coeficiente de Correlación de Spearman (ρ)

Dado que variables como `GenHlth` (Salud General) y `Age` (Edad) están codificadas en escalas ordinales (1-5 y 1-13 respectivamente), el uso del coeficiente de Pearson sería erróneo, ya que este último solo mide relaciones lineales en variables de intervalo.

5.3.1. Justificación del Método

Se utilizó la correlación de Spearman, que mide la relación monótona entre dos variables. Al basarse en la jerarquía de los datos, es menos sensible a los valores atípicos de la variable `BMI` y captura mejor la tendencia de ".ª mayor edad, mayor riesgo.º .ª peor salud percibida, mayor diagnóstico", sin asumir que estos incrementos sean constantes (lineales).

5.4. El Problema del p-valor en Grandes Volúmenes de Datos

Es una consideración matemática importante notar que, con un tamaño de muestra superior a un cuarto de millón de registros, prácticamente cualquier diferencia mínima será ".estadísticamente significativa"($p < 0{,}05$). Por esta razón, en este informe no solo nos basamos en el p-valor, sino también en el **Tamaño del Efecto** y en la **Importancia Relativa** observada en las matrices de correlación. Se concluye que, si bien todas las variables estudiadas muestran dependencia, la salud general (`GenHlth`) y la hipertensión (`HighBP`) poseen la fuerza de asociación más robusta, situándose como los pilares de la inferencia del modelo.

6. Interfaz de Usuario y Resultados en Streamlit

Se desarrolló una aplicación que permite la exploración dinámica. Los siguientes screenshots documentan la funcionalidad y visualizaciones obtenidas:

Figura 4: Panel principal y selector de base de datos.

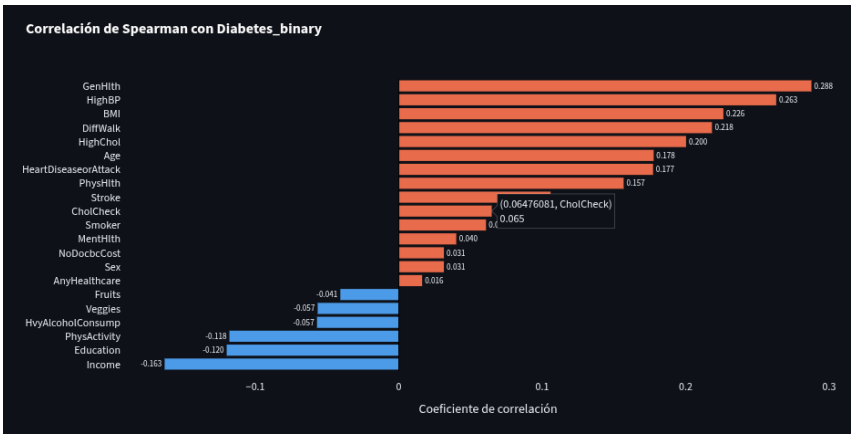

Figura 5: Visualización de estadísticas descriptivas generadas dinámicamente.

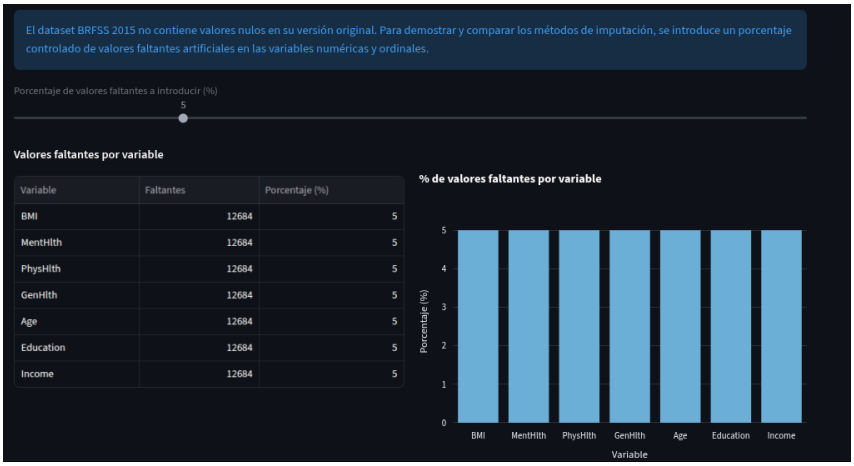

Figura 6: Matriz de correlación para identificación de colinealidad.

7. Conclusiones

El análisis integral del dataset permite extraer los siguientes resultados netos del proyecto:

- **Desbalanceo de Clases:** Se identificó una prevalencia de diabetes del 14 % frente a un 86 % de casos negativos. Este desbalanceo es un factor crítico que condiciona la interpretación de la exactitud global y resalta la necesidad de métricas de sensibilidad en la clasificación.
- **Asociación Biométrica:** El Índice de Masa Corporal (`BMI`) demostró ser un diferenciador clave; el grupo con diabetes presenta una mediana de IMC significativamente superior y una mayor dispersión, validando la obesidad como el predictor físico más robusto.
- **Relevancia de Outliers:** La decisión de preservar valores de IMC superiores a 50 fue acertada, ya que estos representan casos reales de obesidad mórbida que concentran la mayor probabilidad de diagnóstico positivo, aportando información esencial que la depuración convencional habría eliminado.
- **Comorbilidades Dominantes:** La hipertensión arterial y el colesterol alto presentan una prevalencia superior al 42 % en la muestra. Las pruebas de Chi-cuadrado confirmaron una dependencia estadística significativa entre estas condiciones y la presencia de diabetes.
- **Poder de la Autopercepción:** La variable `GenHlth` (Salud General percibida) mostró la correlación más alta con la variable objetivo, superando a indicadores clínicos individuales. Esto sugiere que la percepción subjetiva del paciente es un predictor sintético de alta precisión.
- **Eficacia de la Imputación:** El método **KNN** superó a la imputación por mediana al preservar la varianza original y la estructura multivariada de los datos, evitando el sesgo de centralidad que reduciría la capacidad predictiva de los modelos.
- **Validación Estadística:** Las pruebas de Kruskal-Wallis y Chi-cuadrado arrojaron p-valores inferiores a 0,05, rechazando las hipótesis de independencia y confirmando que las variables seleccionadas poseen capacidad real de separación de clases.